

在第2章中介绍了函数逼近的一种方法——函数的插值或多项式插值,其显著的特点就是要求近似函数(插值函数)在节点处与函数同值,即满足插值条件.在实际工程计算中,由于误差的存在,要求近似函数严格满足插值条件(几何上即相应的曲线通过点 (x_i, y_i))是不现实的.

在科学实验和统计分析中,往往需要从一组实验数据或观测数据 (x_i, y_i) 出发,找出变化规律,求出函数 $y=f(x)$ 的近似表达式.如果利用插值方法,由于数据很多,得到的插值函数很复杂,缺少实用价值;且实验数据往往有误差,没有必要要求它们相等.曲线拟合是从给出的一大堆数据中找出规律,即设法构造一条曲线,不要求该曲线严格地通过每个数据点,只要求它能更加合理地反映数据点总的趋势,在某种意义下与这些数据点的总体偏差最小.这类方法称为曲线(数据)拟合法.

对连续点也有类似问题.设 $f(x)$ 是定义在区间 $[a, b]$ 上的连续函数,但太复杂,应用不便,希望用简单函数 $p(x)$ 去近似 $f(x)$.通常取 $p(x)$ 为多项式、有理分式等,要求在某种意义下 $p(x)$ 与 $f(x)$ 在整个区间 $[a, b]$ 上的总体偏差最小.这类方法称为函数逼近法.

3.1 曲线拟合的最小二乘法

对于一组给定的数据

x	x_1	x_2	$\cdots$	x_m
y	y_1	y_2	$\cdots$	y_m

记通过点 (x_i, y_i) 的规律为 $y=f(x)$,即 $y_i=f(x_i)(i=1, 2, \cdots, m)$.假设“逼近”规律的近似函数为 $y=\varphi(x)$,即 $y_i^*=\varphi(x_i)(i=1, 2, \cdots, m)$.它与观测值 y_i 之差

$$\delta_i = y_i^* - y_i = \varphi(x_i) - y_i, \quad i = 1, 2, \cdots, m$$

称为残差.残差的大小可作为衡量近似函数好坏的标准.

由于观测数据总有误差,所以不要求 $y=\varphi(x)$ 通过已知点 $(x_i, y_i)(i=1, 2, \cdots, m)$.在给定点 $x_i(i=1, 2, \cdots, m)$ 上,按照使残差的平方和 $\sum_{i=1}^m \delta_i^2$ 最小的规则求得近似函数 $y=\varphi(x)$ 的方法称为最佳平方逼近,也称为曲线拟合的最小二乘法.

曲线拟合的最小二乘问题一般提法:根据给定的数据组 $(x_i, y_i)(i=1, 2, \cdots, m)$,选取近

似函数形式, 即给定函数类 $\Phi = \text{Span}\{\varphi_0, \varphi_1, \dots, \varphi_n\}$, 求函数 $\varphi(x) \in \Phi$, 即

$$\varphi(x) = a_0\varphi_0(x) + a_1\varphi_1(x) + \dots + a_n\varphi_n(x) \quad (3.1)$$

使得

$$\begin{aligned} I(a_0, a_1, \dots, a_n) &= \sum_{i=1}^m \rho_i [\varphi(x_i) - y_i]^2 \\ &= \sum_{i=1}^m \rho_i \left[\sum_{j=0}^n a_j \varphi_j(x_i) - y_i \right]^2 \end{aligned} \quad (3.2)$$

达到最小. 这里 $\varphi_0(x), \varphi_1(x), \dots, \varphi_n(x) \in C[a, b]$ 是线性无关的函数族, $\rho_i > 0$ ($i=1, 2, \dots, m$) 为权系数, m 一般比 n 大得多.

求式(3.2)的最小值就是求多元函数 $I(a_0, a_1, \dots, a_n)$ 的极值. 记 $I = I(a_0, a_1, \dots, a_n)$, 由极值的必要条件可得

$$\frac{\partial I}{\partial a_j} = 2 \sum_{i=1}^m \rho_i \left[\sum_{k=0}^n a_k \varphi_k(x_i) - y_i \right] \varphi_j(x_i) = 0, \quad j = 0, 1, \dots, n$$

即

$$\sum_{k=0}^n a_k \left[\sum_{i=1}^m \rho_i \varphi_k(x_i) \varphi_j(x_i) \right] = \sum_{i=1}^m \rho_i y_i \varphi_j(x_i), \quad j = 0, 1, \dots, n \quad (3.3)$$

引入内积定义(带权内积)

$$\begin{cases} (\varphi_j, \varphi_k) = \sum_{i=1}^m \rho_i \varphi_j(x_i) \varphi_k(x_i) \\ (y, \varphi_j) = \sum_{i=1}^m \rho_i y_i \varphi_j(x_i) \end{cases} \quad (3.4)$$

则式(3.3)可改写为

$$(\varphi_0, \varphi_j) a_0 + (\varphi_1, \varphi_j) a_1 + \dots + (\varphi_n, \varphi_j) a_n = (y, \varphi_j), \quad j = 0, 1, \dots, n$$

这是关于参数 $a_0, a_1, \dots, a_n$ 的线性方程组, 用矩阵表示为

$$\begin{bmatrix} (\varphi_0, \varphi_0) & (\varphi_0, \varphi_1) & \cdots & (\varphi_0, \varphi_n) \\ (\varphi_1, \varphi_0) & (\varphi_1, \varphi_1) & \cdots & (\varphi_1, \varphi_n) \\ \vdots & \vdots & \ddots & \vdots \\ (\varphi_n, \varphi_0) & (\varphi_n, \varphi_1) & \cdots & (\varphi_n, \varphi_n) \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} (y, \varphi_0) \\ (y, \varphi_1) \\ \vdots \\ (y, \varphi_n) \end{bmatrix} \quad (3.5)$$

线性方程组(3.5)称为法方程.

函数族 $\{\varphi_j(x)\} (j=0, 1, \dots, n)$ 线性无关不能保证式(3.5)的系数矩阵非奇异. 因此, 要使法方程(3.5)有唯一解 $a_0, a_1, \dots, a_n$, 必须加上另外的条件(本书略去, 读者可参见文献[1]).

3.2 最小二乘法的求法

3.2.1 多项式拟合

在最小二乘拟合中, 若取 $\varphi_j(x) = x^j$ ($j=0, 1, \dots, n$), 则 $\varphi(x) \in \text{Span}\{1, x, \dots, x^n\}$, 即

$$\varphi(x) = a_0 + a_1 x + \dots + a_n x^n \quad (3.6)$$

此时关于系数 $a_0, a_1, \dots, a_n$ 的法方程(3.5)是病态方程,通常当 $n \geq 3$ 时都不直接取 $\varphi_k(x) = x^k$ 作为基. 这里只给出 $n=2, \rho_i=1$ 时的情形. 由法方程(3.5)可得

$$\begin{cases} ma_0 + a_1 \sum_{i=1}^m x_i + a_2 \sum_{i=1}^m x_i^2 = \sum_{i=1}^m y_i \\ a_0 \sum_{i=1}^m x_i + a_1 \sum_{i=1}^m x_i^2 + a_2 \sum_{i=1}^m x_i^3 = \sum_{i=1}^m y_i x_i \\ a_0 \sum_{i=1}^m x_i^2 + a_1 \sum_{i=1}^m x_i^3 + a_2 \sum_{i=1}^m x_i^4 = \sum_{i=1}^m y_i x_i^2 \end{cases} \quad (3.7)$$

解出 a_0, a_1, a_2 , 就得到拟合公式 $y = a_0 + a_1 x + a_2 x^2$.

例 3.1 已知某单位 2001—2007 年的利润为

时间/年	2001	2002	2003	2004	2005	2006	2007
利润/万元	72	108	140	150	174	196	208

试预测 2008 年的利润.

解 由已知数据作出散点图(如图 3.1 所示),可见该单位的年利润几乎直线上升. 我们选择一次多项式作为拟合函数来预测 2008 年的利润. 为简化计算,将年份记为 $x_i = 2000 + t_i$, 相应年份的利润记作 $y_i (i=1, 2, \dots, 7)$, 则所求的拟合函数为 $y = a + bt$. 计算得

$$\sum_{i=1}^7 t_i = 28, \quad \sum_{i=1}^7 t_i^2 = 140, \quad \sum_{i=1}^7 y_i = 1048, \quad \sum_{i=1}^7 t_i y_i = 4810$$

从而得方程组

$$\begin{cases} 7a + 28b = 1048 \\ 28a + 140b = 4810 \end{cases}$$

解得 $a = \frac{430}{7}, b = \frac{309}{14}$. 于是所求拟合函数为




图 3.1 散点图

$$y = \frac{430}{7} + \frac{309}{14}t$$

将 $t=8$ 代入, 得 2008 年的利润为

$$y = \frac{430}{7} + \frac{309}{14} \times 8 = \frac{1666}{7} = 238 \text{ (万元)}$$

例 3.2 求下列数据的最小二乘二次拟合多项式.

x_i	-1	-0.75	-0.5	-0.25	0	1	0.75	0.5	0.25
y_i	-0.2209	0.3295	0.8826	1.4392	2.0003	2.5645	3.1334	3.7601	4.2836

解 依题意, 设二次拟合多项式为 $p_2(x) = a_0 + a_1x + a_2x^2$, 将数据代入式 (3.7) 得线性方程组

$$\begin{cases} 9a_0 + 0 + 3.75a_2 = 18.1723 \\ 0 + 3.75a_1 + 0 = 8.4842 \\ 3.75a_0 + 0 + 2.7656a_2 = 7.6173 \end{cases}$$

解得 $a_0 = 2.0034, a_1 = 2.2625, a_2 = 0.0378$. 所以此数据组的最小二乘二次拟合多项式为

$$p_2(x) = 2.0034 + 2.2625x + 0.0378x^2$$

3.2.2 可化为线性拟合的非线性拟合

使用最小二乘逼近时, 模型的选择是很重要的, 通常模型 $y = \varphi(x)$ 是由物理规律或数据分布情况确定的, 不一定是线性模型. 但有的非线性拟合曲线可以经过适当的变换转化为线性曲线, 从而用线性拟合进行处理. 对于一个实际的曲线拟合问题, 一般先按观测值在直角坐标平面上描出散点图, 然后根据散点图选用相接近的模型 (曲线拟合方程), 再通过适当的变量替换化为线性拟合问题. 按线性拟合解出后要再还原为原变量所表示的曲线拟合方程.

例如, 指数函数 $y = ae^{bx}$ 关于系数 a, b 并非线性, 但对它两端取对数得到

$$\ln y = \ln a + bx$$

若令 $\bar{y} = \ln y, A = \ln a$, 则上式转化为 $\bar{y} = A + bx$, 它是线性模型, 仍可按上面介绍的方法求 $y = \varphi(x)$.

表 3.1 列举了可线性化的几类曲线方程.

表 3.1 曲线拟合方程及变换关系

拟合曲线	变换关系	变换后方程
$y = ax^b$	$\bar{y} = \ln y, \bar{x} = \ln x, \bar{a} = \ln a$	$\bar{y} = \bar{a} + b\bar{x}$
$y = a + \frac{b}{x}$	$\bar{x} = \frac{1}{x}$	$\bar{y} = a + b\bar{x}$
$y = \frac{x}{ax + b}$	$\bar{y} = \frac{1}{y}, \bar{x} = \frac{1}{x}$	$\bar{y} = a + b\bar{x}$